

Optuna, Registro de Experimentos y Regularización

Ailin Atala Beltrán Guzmán

15 de septiembre de 2026

Índice

1. Introducción	2
2. Conjunto de datos y preprocesamiento	2
3. Diseño de la red neuronal	3
4. Búsqueda de hiperparámetros con Optuna	3
5. Resultados de la búsqueda con Optuna	3
6. Evaluación del modelo base	4
7. Aplicación de técnicas de regularización	5
8. Resultados de la regularización	6
8.1. Regularización L1	6
8.2. Regularización L2	7
8.3. Regularización L1-L2	7
8.4. Dropout	8
8.5. Dropout combinado con L1-L2	9
9. Discusión	9
10.Registro de experimentos	10

1. Introducción

Las redes neuronales artificiales constituyen una herramienta ampliamente utilizada para resolver problemas de clasificación debido a su capacidad para aprender relaciones complejas a partir de los datos. En este trabajo se emplea una red neuronal densa de tipo secuencial para resolver el problema de clasificación de imágenes correspondiente al conjunto de datos MNIST.

El objetivo principal de la actividad es diseñar y evaluar una red neuronal mediante una búsqueda automatizada de hiperparámetros utilizando Optuna. Posteriormente, se analiza el efecto de diferentes técnicas de regularización sobre la capacidad de generalización de la arquitectura seleccionada.

La primera etapa consiste en realizar una búsqueda de arquitecturas sin utilizar regularización, variando características como el número de capas, número de neuronas, función de activación, optimizador, tasa de aprendizaje y tamaño del lote. Los experimentos generados durante esta etapa se registran mediante MLflow y se visualizan utilizando DagsHub.

En la segunda etapa se toma la mejor arquitectura encontrada y se evalúa utilizando diferentes técnicas de regularización: L1, L2, L1-L2, Dropout y una combinación de Dropout con regularización L1-L2. Finalmente, se comparan los resultados obtenidos con el modelo base para determinar qué estrategia proporciona el mejor equilibrio entre desempeño y generalización.

2. Conjunto de datos y preprocesamiento

Para los experimentos se utilizó el conjunto de datos MNIST, disponible mediante la biblioteca Keras de TensorFlow. El conjunto está compuesto por imágenes de dígitos manuscritos correspondientes a las clases del 0 al 9.

El conjunto de datos contiene 60,000 imágenes para entrenamiento y 10,000 imágenes para prueba. Cada imagen tiene dimensiones de 28×28 píxeles, por lo que cada observación contiene un total de 784 características.

El conjunto de entrenamiento se utilizó para realizar el entrenamiento y la validación de los modelos, mientras que el conjunto de prueba se reservó para la evaluación final.

De acuerdo con la implementación vista en clase, las imágenes fueron transformadas de matrices bidimensionales a vectores de 784 elementos. Posteriormente, los valores de los píxeles fueron normalizados dividiéndolos entre 255, de manera que los valores se encontraran en el intervalo $[0, 1]$.

Las etiquetas fueron transformadas mediante codificación one-hot para representar las diez clases disponibles.

Por lo tanto, después del preprocesamiento se obtuvieron las siguientes dimensiones:

- Datos de entrenamiento: (60000, 784).
- Datos de prueba: (10000, 784).
- Etiquetas de entrenamiento: (60000, 10).
- Etiquetas de prueba: (10000, 10).

Durante el entrenamiento se utilizó el 90 % de los datos de entrenamiento para ajustar los parámetros de la red y el 10 % restante como conjunto de validación mediante el parámetro `validation_split=0.1`.

3. Diseño de la red neuronal

Se diseñó una red neuronal densa secuencial utilizando Keras. La capa de entrada recibe un vector de 784 características, correspondiente a los píxeles de cada imagen.

La capa de salida está constituida por 10 neuronas, una por cada clase del conjunto MNIST, utilizando la función de activación *softmax*. La función de pérdida utilizada fue la entropía cruzada categórica (*Categorical Crossentropy*).

La arquitectura intermedia no fue fijada inicialmente, sino que se determinó mediante una búsqueda de hiperparámetros utilizando Optuna.

4. Búsqueda de hiperparámetros con Optuna

Para determinar una arquitectura adecuada se utilizó Optuna, una herramienta de optimización automática de hiperparámetros.

En esta primera etapa no se incorporaron técnicas de regularización, con el objetivo de determinar una arquitectura base antes de estudiar el efecto de L1, L2 y Dropout.

El espacio de búsqueda utilizado fue el siguiente:

Cuadro 1: Espacio de búsqueda utilizado con Optuna.

Hiperparámetro	Espacio de búsqueda
Número de capas densas	1–4
Neuronas por capa	64–512, incremento de 64
Función de activación	ReLU, Tanh, Sigmoid
Optimizador	Adam, RMSprop, SGD
Tasa de aprendizaje	10^{-4} – 10^{-2}
Tamaño de lote	64, 128, 256

Se realizaron 20 experimentos (*trials*) y cada uno se entrenó durante 10 épocas. Como función objetivo se utilizó la mayor exactitud obtenida sobre el conjunto de validación.

La regularización no fue incluida dentro del espacio de búsqueda, de acuerdo con los requerimientos de la actividad.

Los experimentos fueron registrados mediante MLflow y almacenados en DagsHub para facilitar su seguimiento y comparación.

5. Resultados de la búsqueda con Optuna

Después de realizar los 20 experimentos, la mejor configuración obtuvo una exactitud de validación de aproximadamente 98.43 %.

La arquitectura seleccionada fue:

- Número de capas ocultas: 3.

- Primera capa: 448 neuronas.
- Segunda capa: 384 neuronas.
- Tercera capa: 192 neuronas.
- Función de activación: ReLU.
- Capa de salida: 10 neuronas con activación Softmax.
- Optimizador: RMSprop.
- Tasa de aprendizaje: 0.0011786.
- Tamaño de lote: 64.

Model: "sequential"

Layer (type)	Output Shape	Param #
dense (Dense)	(None, 448)	351,680
dense_1 (Dense)	(None, 384)	172,416
dense_2 (Dense)	(None, 192)	73,920
dense_3 (Dense)	(None, 10)	1,030

Total params: 599,046 (2.29 MB)
Trainable params: 599,046 (2.29 MB)
Non-trainable params: 0 (0.00 B)

Figura 1: Mejor Arquitectura obtenida

Todas las capas ocultas corresponden a capas densas con activación ReLU.

El registro de los experimentos realizados mediante Optuna puede consultarse en el repositorio de DagsHub:

https://dagshub.com/AilinBG/Red_Densa


6. Evaluación del modelo base

Una vez identificada la mejor configuración mediante Optuna, se reconstruyó la arquitectura seleccionada y se entrenó durante 30 épocas utilizando los mismos hiperparámetros.

El propósito de este entrenamiento fue establecer un modelo base contra el cual posteriormente pudieran compararse las diferentes técnicas de regularización.

Al finalizar el entrenamiento, el modelo base obtuvo:

- Accuracy de entrenamiento: 99.99 %.
- Accuracy de validación: 98.43 %.
- Mejor accuracy de validación: 98.58 %.
- Accuracy en prueba: 98.48 %.



La diferencia entre la exactitud de entrenamiento y validación al finalizar el entrenamiento fue aproximadamente:

$$99.99\% - 98.53\% = 1.45\%.$$

Esta diferencia indica la presencia de una brecha de generalización. El modelo logra prácticamente memorizar los datos de entrenamiento, mientras que su desempeño sobre datos no utilizados directamente para ajustar sus parámetros es ligeramente inferior.

Por esta razón, el modelo base constituye un punto de referencia adecuado para analizar el efecto de las técnicas de regularización.

7. Aplicación de técnicas de regularización

A partir de la arquitectura obtenida mediante Optuna se realizaron cinco experimentos adicionales incorporando diferentes técnicas de regularización.

Para garantizar una comparación consistente, se mantuvieron constantes la arquitectura y los principales hiperparámetros del modelo base. Las técnicas evaluadas fueron:

1. Regularización L1.
2. Regularización L2.
3. Regularización L1-L2.
4. Dropout.
5. Dropout combinado con L1-L2.

Para L1 se utilizó un coeficiente de 0.0001. Para L2 se utilizó igualmente un coeficiente de 0.0001. En el caso de L1-L2 se utilizaron ambos coeficientes con valor 0.0001.

Para Dropout se utilizó una tasa de 0.3 después de cada una de las tres capas ocultas.

Todos los modelos fueron entrenados durante 30 épocas con un tamaño de lote de 64 y utilizando RMSprop con una tasa de aprendizaje de 0.0011786.

8. Resultados de la regularización

La Tabla 2 presenta los resultados obtenidos para el modelo base y las cinco configuraciones de regularización.

Cuadro 2: Comparación de los modelos evaluados.


Modelo	Train Acc.	Val Acc.	Mejor Val Acc.	Test Acc.	Brecha Train-Val
Baseline	99.99 %	98.53 %	98.58 %	98.48 %	1.45 %
L1	98.15 %	97.62 %	97.98 %	97.26 %	0.53 %
L2	99.00 %	98.10 %	98.30 %	97.99 %	0.90 %
L1-L2	97.98 %	97.70 %	97.78 %	97.44 %	0.28 %
Dropout	99.20 %	98.48 %	98.72 %	98.59 %	0.72 %
Dropout + L1-L2	94.92 %	97.40 %	97.90 %	96.87 %	-2.48 %

8.1. Regularización L1

La regularización L1 redujo considerablemente la brecha entre el desempeño de entrenamiento y validación, pasando de 1.45 % en el modelo base a 0.53 %.

Sin embargo, esta reducción de la brecha estuvo acompañada de una disminución en el desempeño general. La exactitud sobre el conjunto de prueba fue de 97.26 %, inferior al 98.48 % obtenido por el modelo base.

Por lo tanto, aunque L1 contribuyó a reducir la diferencia entre entrenamiento y validación, en este experimento produjo una pérdida de capacidad predictiva.




8.2. Regularización L2

El modelo con regularización L2 obtuvo una brecha entrenamiento-validación de 0.90 %, menor que la del modelo base.

Su accuracy en el conjunto de prueba fue de 97.99 %. Aunque el resultado fue inferior al modelo base, la reducción de la brecha muestra que la regularización L2 ayudó a limitar el sobreajuste.

No obstante, la pérdida de accuracy indica que el nivel de regularización utilizado no proporcionó una mejora global en el desempeño.




8.3. Regularización L1-L2

La combinación de L1 y L2 produjo la menor brecha positiva entre entrenamiento y validación, con un valor de 0.28 %.

Sin embargo, este resultado no se tradujo en una mayor capacidad predictiva. El accuracy sobre el conjunto de prueba fue de 97.44 %, inferior tanto al modelo base como al modelo con Dropout.

Este resultado muestra que reducir el sobreajuste no necesariamente implica obtener una mayor exactitud sobre datos no vistos.



8.4. Dropout

El modelo con Dropout presentó el mejor resultado entre todas las configuraciones evaluadas.


La mejor exactitud de validación fue de 98.72 %, mientras que la exactitud obtenida sobre el conjunto de prueba fue de 98.59 %.

Este último valor representa una mejora respecto al modelo base:

$$98.59 \% - 98.48 \% = 0.11 \ \%.$$

Además, la brecha entre entrenamiento y validación disminuyó de 1.45 % en el modelo base a 0.72 %.

Por lo tanto, dentro de los experimentos realizados, Dropout fue la técnica que proporcionó el mejor equilibrio entre reducción del sobreajuste y desempeño predictivo.




8.5. Dropout combinado con L1-L2

La combinación de Dropout con regularización L1-L2 produjo el peor desempeño sobre el conjunto de prueba, con una exactitud de 96.87 %.

La exactitud de entrenamiento fue de 94.92 %, mientras que la de validación fue de 97.40 %. La diferencia negativa entre ambos valores se explica por el comportamiento de Dropout durante el entrenamiento: las unidades se desactivan aleatoriamente durante esta etapa, mientras que durante la validación se evalúa la red sin aplicar dicha desactivación.

En este caso, la combinación de ambas estrategias resultó demasiado restrictiva para la arquitectura utilizada, provocando una disminución considerable del desempeño.



9. Discusión

Los resultados muestran que la regularización tuvo efectos diferentes dependiendo de la técnica empleada.

El modelo base presentó el mayor desempeño de entrenamiento, alcanzando prácticamente el 100 %, pero también mostró la mayor brecha entre entrenamiento y validación. Esto constituye una señal de que la red tiene suficiente capacidad para ajustarse fuertemente a los datos de entrenamiento.

Las técnicas L1, L2 y L1-L2 lograron disminuir esta brecha. En particular, L1-L2 obtuvo la menor diferencia positiva entre entrenamiento y validación. Sin embargo, esta mejora en términos de generalización estuvo acompañada de una reducción en la exactitud sobre el conjunto de prueba.

El resultado más favorable fue obtenido mediante Dropout. Esta técnica permitió reducir la brecha de generalización y, al mismo tiempo, obtener una accuracy de prueba ligeramente superior a la del modelo base.

La comparación también muestra que utilizar una mayor cantidad de regularización no implica necesariamente obtener mejores resultados. La combinación de Dropout con L1-L2 produjo una reducción importante del desempeño, lo que sugiere que para esta arquitectura la combinación de ambas estrategias fue excesiva.

Por lo tanto, la selección de una técnica de regularización debe considerar simultáneamente la capacidad de generalización y el desempeño predictivo, y no únicamente la reducción de la diferencia entre las métricas de entrenamiento y validación.

10. Registro de experimentos

Los experimentos realizados durante la búsqueda de hiperparámetros y durante la evaluación de las técnicas de regularización fueron registrados mediante MLflow y almacenados en DagsHub.

En la primera etapa se registraron los 20 experimentos correspondientes a la búsqueda de Optuna, además del experimento correspondiente a la mejor configuración encontrada.

En la segunda etapa se registraron los experimentos correspondientes al modelo base y a cada una de las cinco estrategias de regularización.

El repositorio utilizado para el seguimiento de los experimentos es:

https://dagshub.com/AilinBG/Red_Densa

Este registro permite consultar los parámetros utilizados y las métricas obtenidas en los diferentes experimentos, facilitando la reproducibilidad y comparación de los resultados.